GARCH-Informed Deep Learning with Shared Parameters for Multi-Asset Volatility Forecasting

基於參數共享與 GARCH 輔助之多資 產波動率預測

National Taiwan University | Applied Deep Learning Final Project

Team 9

Team Members: 蔡宇傑, 高大剛, 柯宥圻,黃和謙,姚暐,郭宥真

Executive Summary

核心問題

傳統 GARCH 模型反應滯後，而純深度學習模型容易過擬合且缺乏金融理論支撐。

- **研究背景：** 根據Xu et al.(2024) "GARCH-Informed" 混合損失函數，結合計量經濟學與深度學習的非線性擬合能力。
- **關鍵技術：** 利用TSMixer的參數共享 (Shared Parameters) 機制，以跨資產資訊消除個股特異性雜訊。
- **主要發現：** TSMixer 在 MAE 指標上顯著優於 GARCH 與 LSTM；lambda = 0.3 是平衡整體誤差與極端風險 (tail risk) 的最佳點。

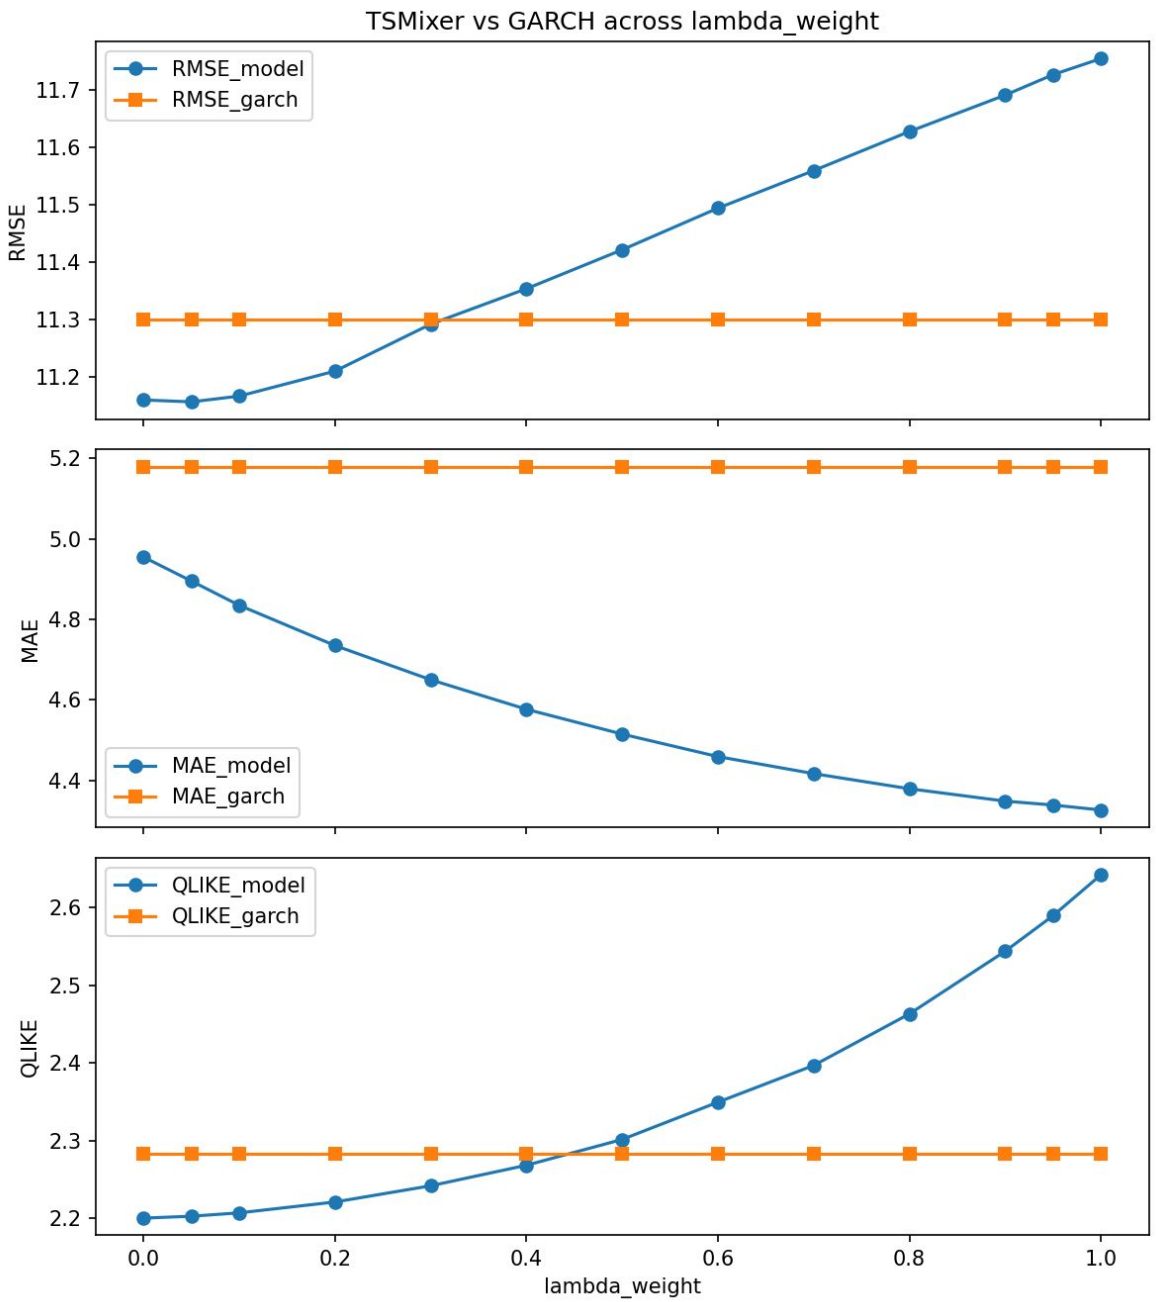

Motivation: The Modeling Dilemma

GARCH Family Limits (計量經濟模型):

線性假設: 假設未來波動率是過去殘差的線性組合。

反應滯後: 對結構性突變(如 COVID-19、金融危機)適應緩慢。

對稱性偏差: 普通 GARCH 模型無法捕捉「槓桿效應」(負向衝擊對波動性的影響更大)。

Deep Learning Issues (深度學習模型)

過擬合風險: 高維度金融數據雜訊極大，且模型可能會學到特定時間錯誤精細特徵。

黑箱問題: 深度學習模型可能缺乏可解釋性和理論基礎。

數據匱乏: 個股往往缺乏足夠的歷史數據來建構複雜的模型。

目標:建立一個兼具 GARCH 的穩定性和 DL 的靈活性的混合模型。

Motivation: Our Approach

本研究核心目的:結合傳統金融理論的穩定性與深度學習的靈活性。

1. GARCH-Informed Loss

將 GARCH 模型的預測值作為深度學習損失函數的一部分(Inductive Bias), 引導模型學習。

2. Shared Parameters (TSMixer)

使用 TSMixer 進行多資產參數共享, 利用全體股票的共同特徵來過濾個股的特異性噪聲 (Idiosyncratic Noise)。

Lit. Review I: The Evolution of GARCH

Econometrics

From Symmetry to Asymmetry

Traditional GARCH assumes symmetric impact of shocks. Variants were developed to address this:

- **EGARCH (Nelson, 1991):** Models log-variance to handle negative shocks without non-negativity constraints.
- **GJR-GARCH (Glosten et al., 1993):** Introduces indicator functions to explicitly model the "Leverage Effect".
- **APARCH (Ding et al., 1993):** Generalized power parameter to nest other models.

The "Complexity Paradox"

Despite theoretical flexibility, complex variants often fail to outperform simple GARCH out-of-sample.

- *"Complexity increases fitting but degrades robustness during crisis periods." (Dol, 2021)*

Implication for Our Work: We use GARCH variants as *expert features/priors* rather than standalone predictors, allowing the Neural Network to decide when to trust them.

Lit. Review II: Feature Engineering & Alpha 101

Quant Factors

Market Microstructure

- **Volume-Volatility Relation:** Trading volume is positively correlated with price volatility *(Karpoff, 1987)*.
- **Calendar Anomalies:** Day-of-the-week effects influence volatility clustering *(French & Roll, 1986)*.

Alpha 101 Factors

Kakushadze (2015): 101 formulaic trading alphas generated via Genetic Algorithms.

While designed for returns, they exhibit sub-linear relationships with volatility, providing rich high-dimensional signals.

The Challenge: Signal Decay

McLean & Pontiff (2016): "Predictive power of public signals diminishes over time due to arbitrage."

Solution: Instead of relying on static factors, we use **Deep Learning** to dynamically extract non-linear combinations of these decaying signals.

Lit. Review III: Deep Learning Paradigms

AI Models

Era	Key Model	Characteristics & Limitations
RNN Era (2014-2018)	**LSTM / GRU** (Hochreiter, 1997)	✓ Captures long-term dependency. ✗ **Recursive error accumulation** in multi-step forecasting. ✗ Slow sequential training.
Probabilistic (2020)	**DeepAR** (Salinas et al.)	✓ Outputs probability distributions (good for VaR). ✗ **Univariate:** Ignores cross-asset correlations.
Modern MLP (2023-Present)	**TSMixer** (Chen et al.)	✓ **All-MLP:** High efficiency & interpretability. ✓ **Cross-Variate Mixing:** Explicitly models interaction between ✓ Alpha factors and Volatility.

Dataset & Features

Data Source: TEJ TQuant

- **Universe:** Taiwan 50 Index (0050) constituents.
- **Period:** Jan 2005 - Nov 2025 (20 years).
- **Target:** Log-Volatility $\ln(1+\sigma_t^2)$
- **Features:** 價量、alphas、公司事件指標等

Table 1: Dataset structure

Stock ID	Date	σ_t^2	Earnings	Financials	Alpha 001–172
1216	2005-01-01	...	0	0	...
2330	2005-01-01	...	1	0	...
⋮	⋮	⋮	⋮	⋮	⋮
5880	2025-11-26	...	0	0	...
6505	2025-11-26	...	0	0	...

Feature Engineering

Feature Type	Description
Alpha 101	Kakushadze's 101 formulaic alphas (Price/Volume).
Volume	70+ derived volume momentum indicators.
Events	Earnings Announcements & Financial Statements.

解法：將因子映射至 [-1, 1] 區間。公式：x_norm = 2 * (rank(x) - 1) / (N - 1) - 1。這保留了因子的相對排序資訊，但消除了極端值對神經網路梯度的負面影響。

問題：時間序列模型可能因不同樣本之間的尺度與分佈差異（distribution shift），導致學到偏頗的表示。

解法：RevIN 透過對「每個樣本獨立進行正規化，並在輸出端可逆地還原尺度」，對時間序列的分佈偏移進行動態調整。讓模型專注學習時間動態而非絕對數值，確保了模型不會過度關注高波動股票，從而提升泛化能力。

Preprocessing Pipeline: Dealing with Noise

1 Rank Normalization

問題：Alpha 因子呈現極端厚尾分佈(Heavy Tails) 與極端峰度。

解法：將因子映射至 [-1, 1] 區間。公式：x_norm = 2 * (rank(x) - 1) / (N - 1) - 1。這保留了因子的相對排序資訊，但消除了極端值對神經網路梯度的負面影響。

2 Z-Score Standardization

問題：不同股票之間的波動率水準差異巨大(Scale Heterogeneity)。

解法：使用訓練集的統計量對每支股票的波動率進行標準化。這確保了模型不會過度關注高波動股票，而是學習波動的通用模式。

3 RevIN (Reversible Instance Normalization)

問題：時間序列模型可能因不同樣本之間的尺度與分佈差異（distribution shift），導致學到偏頗的表示。

解法：RevIN 透過對「每個樣本獨立進行正規化，並在輸出端可逆地還原尺度」，對時間序列的分佈偏移進行動態調整。讓模型專注學習時間動態而非絕對數值，確保了模型不會過度關注高波動股票，從而提升泛化能力。

Exploratory Data Analysis (EDA)

Feature Distributions

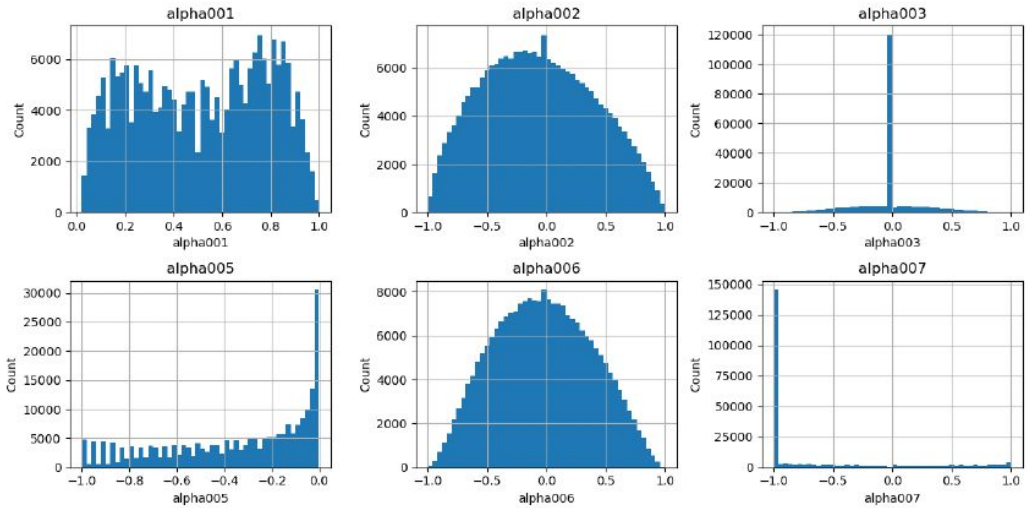

Figure 1: Histograms of selected Alpha 101 factors.

顯示特徵標準化前的分佈情形。

Non-Linearity

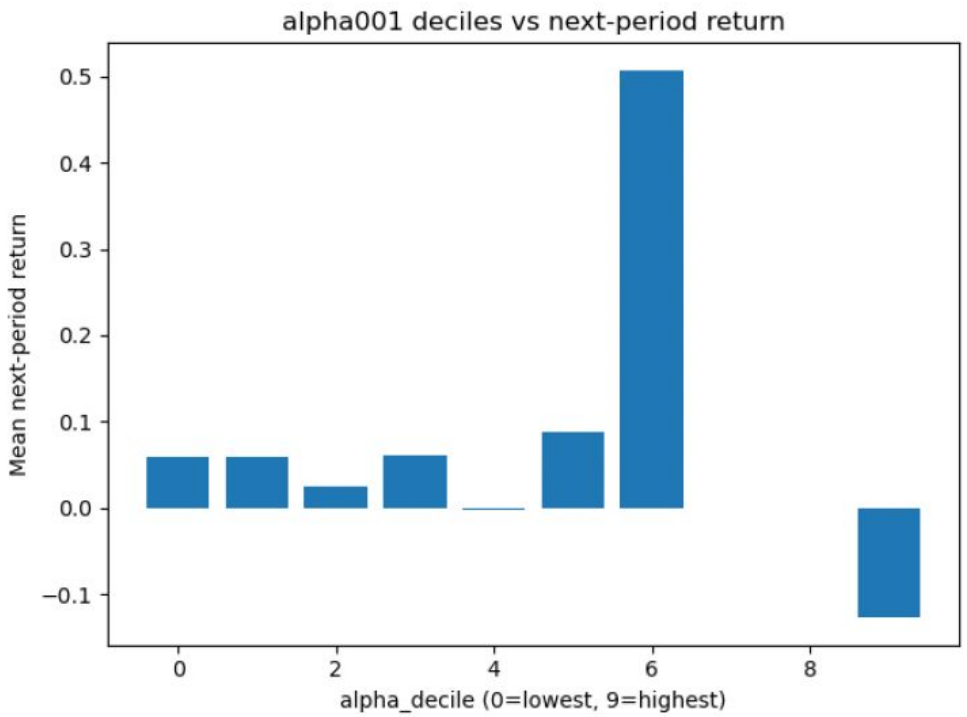

非線性關係證據：極端分位數 (Deciles) 的因子值往往對應更高的波動或價格反轉。這種非線性關係證明了使用DL模型 的必要性。

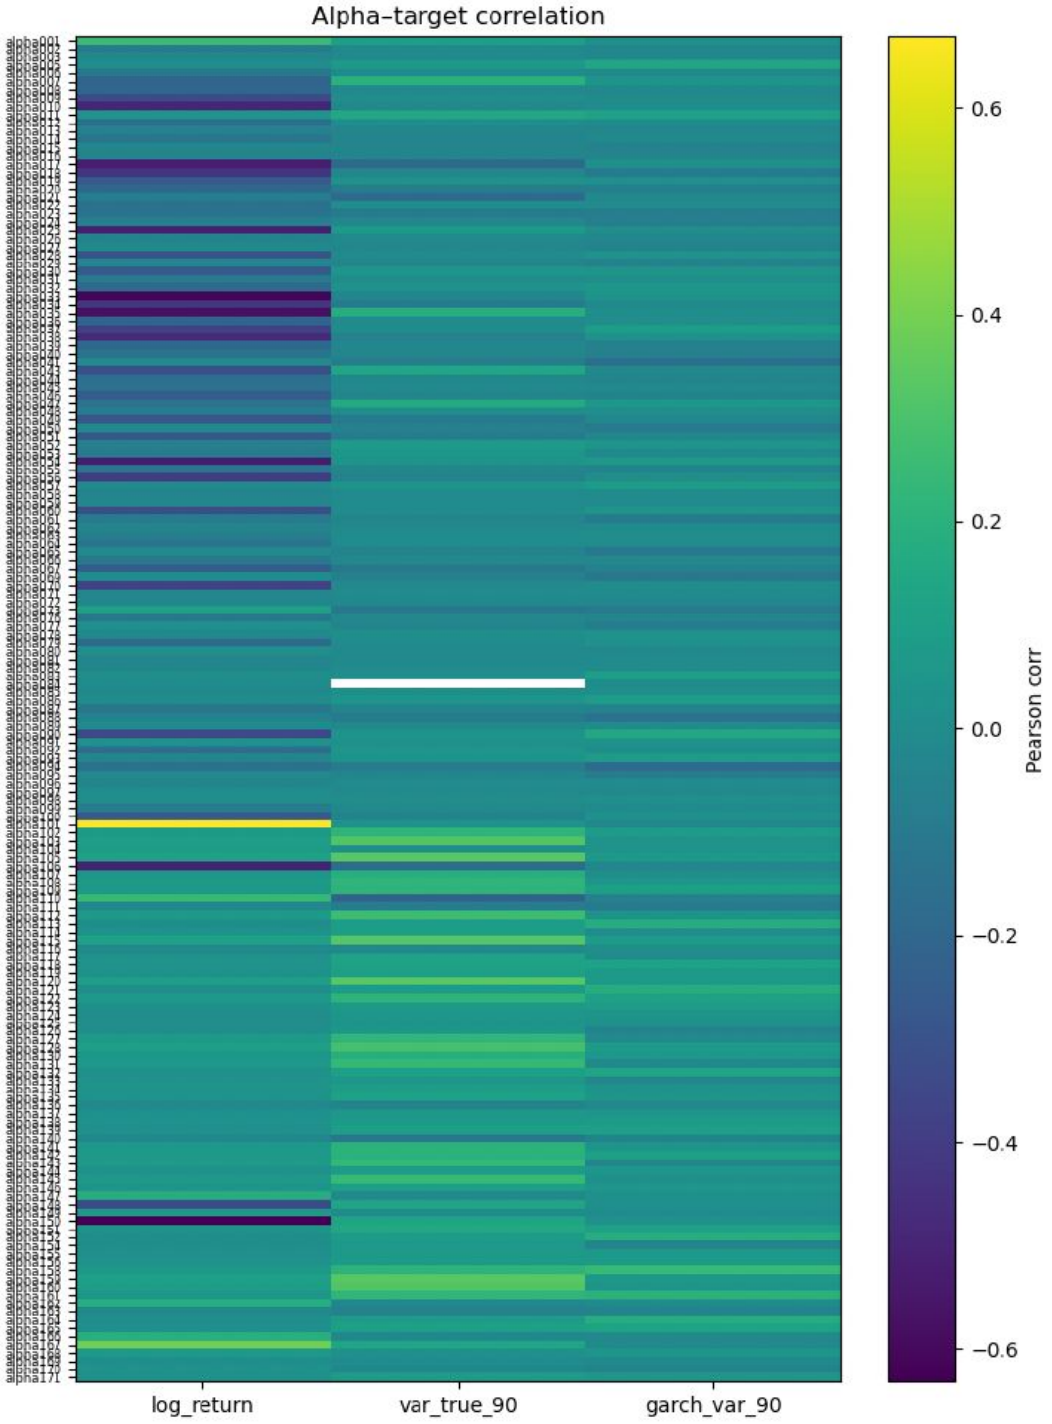

Exploratory Data Analysis (EDA)

Correlation Matrix

部分Alpha 因子與波動率目標呈現顯著相關。Alpha 因子不僅能預測報酬，與波動率 (Variance) 也有顯著相關性(圖中亮色區域)，證明其具備預測價值。

Why TSMixer?

Tsmixer Architecture

TSMixer 是一款全 MLP 構架模型，透過輪替「時間軸」與「特徵軸」的線性混合，取代複雜的注意力機制。它具備線性複雜度，能在極低運算成本下，利用 HPC 並行優勢高效完成精準的時間序列預測。

優點一：All-MLP Structure

以純多層感知器取代循環（如LSTM/ GRU）機制。

優點二：效率

相較於transformer 的複雜度 O(N^2), 具有更快的 O(N) 訓練速度。

優點三：直接多步驟法

避免遞迴 LSTM 預測中固有的誤差累積。

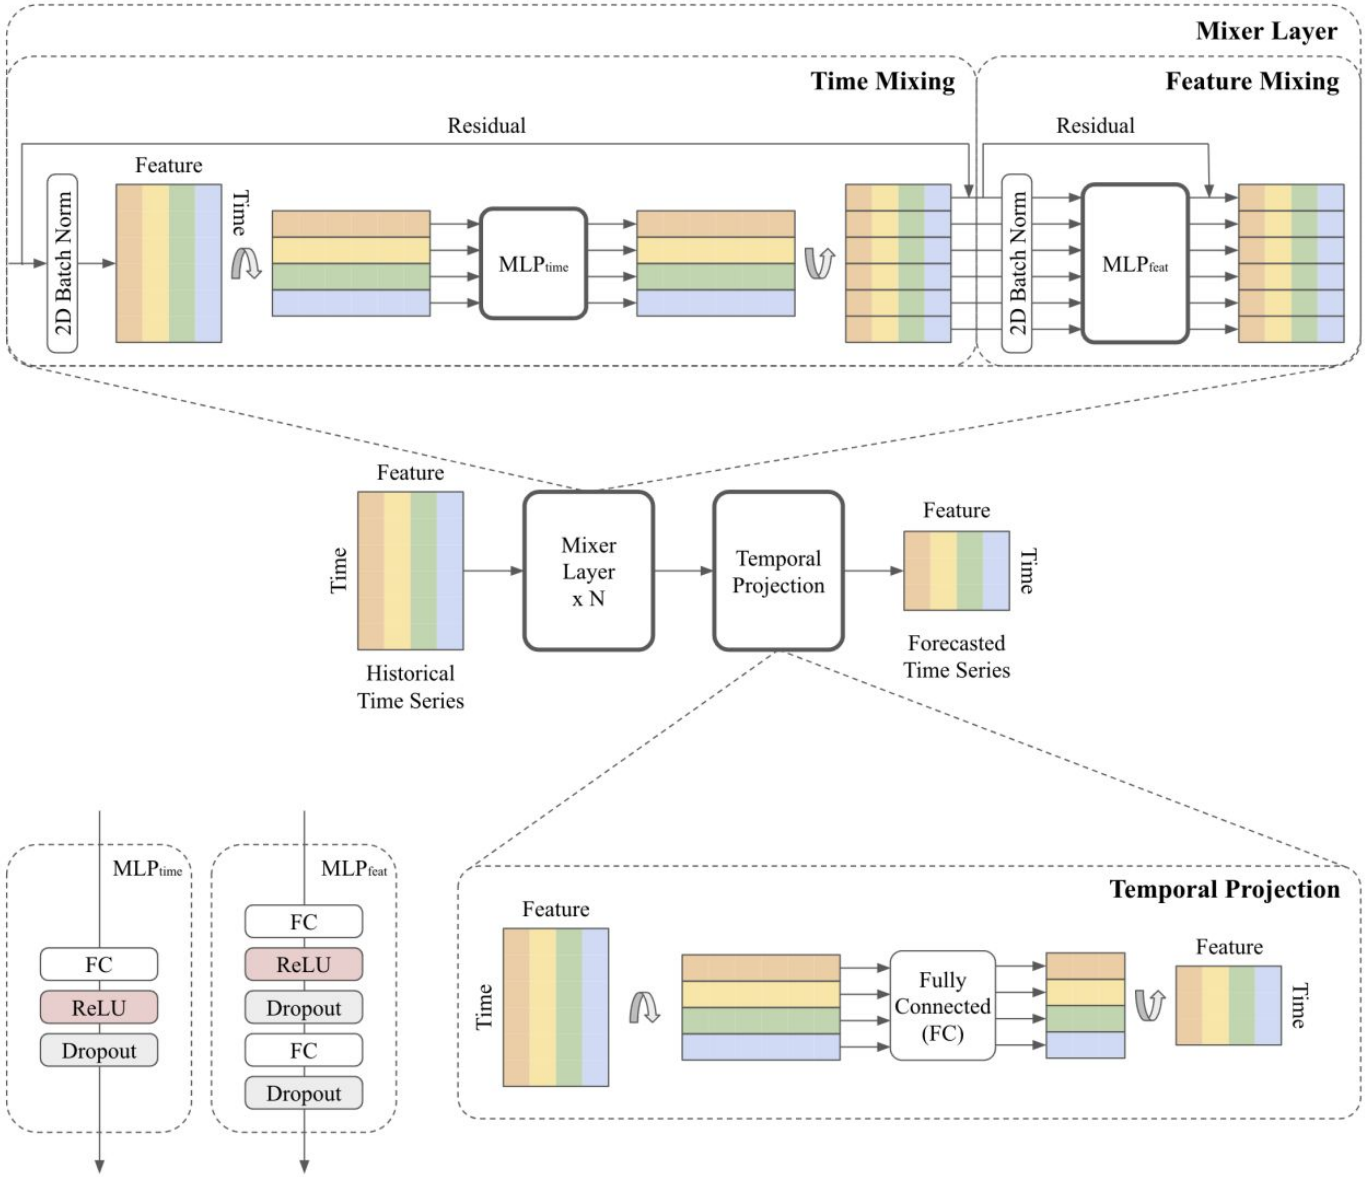

TSMixer vs Baseline Models

Parameter Sharing

同時對所有 50 隻股票進行單一模型訓練，以學習可推廣的市場動態

TSMixer Models

用於前述的TSMixer的優勢和特徵，進行建模並預測波動性

Baseline Models

- GARCH(1,1), GJR-GARCH, TGARCH : 只能對各檔股票分別單獨估計
- LSTM : 雖然可以捕捉長期的短期記憶，但在高維度特徵下容易過度擬合，而且訓練速度較慢

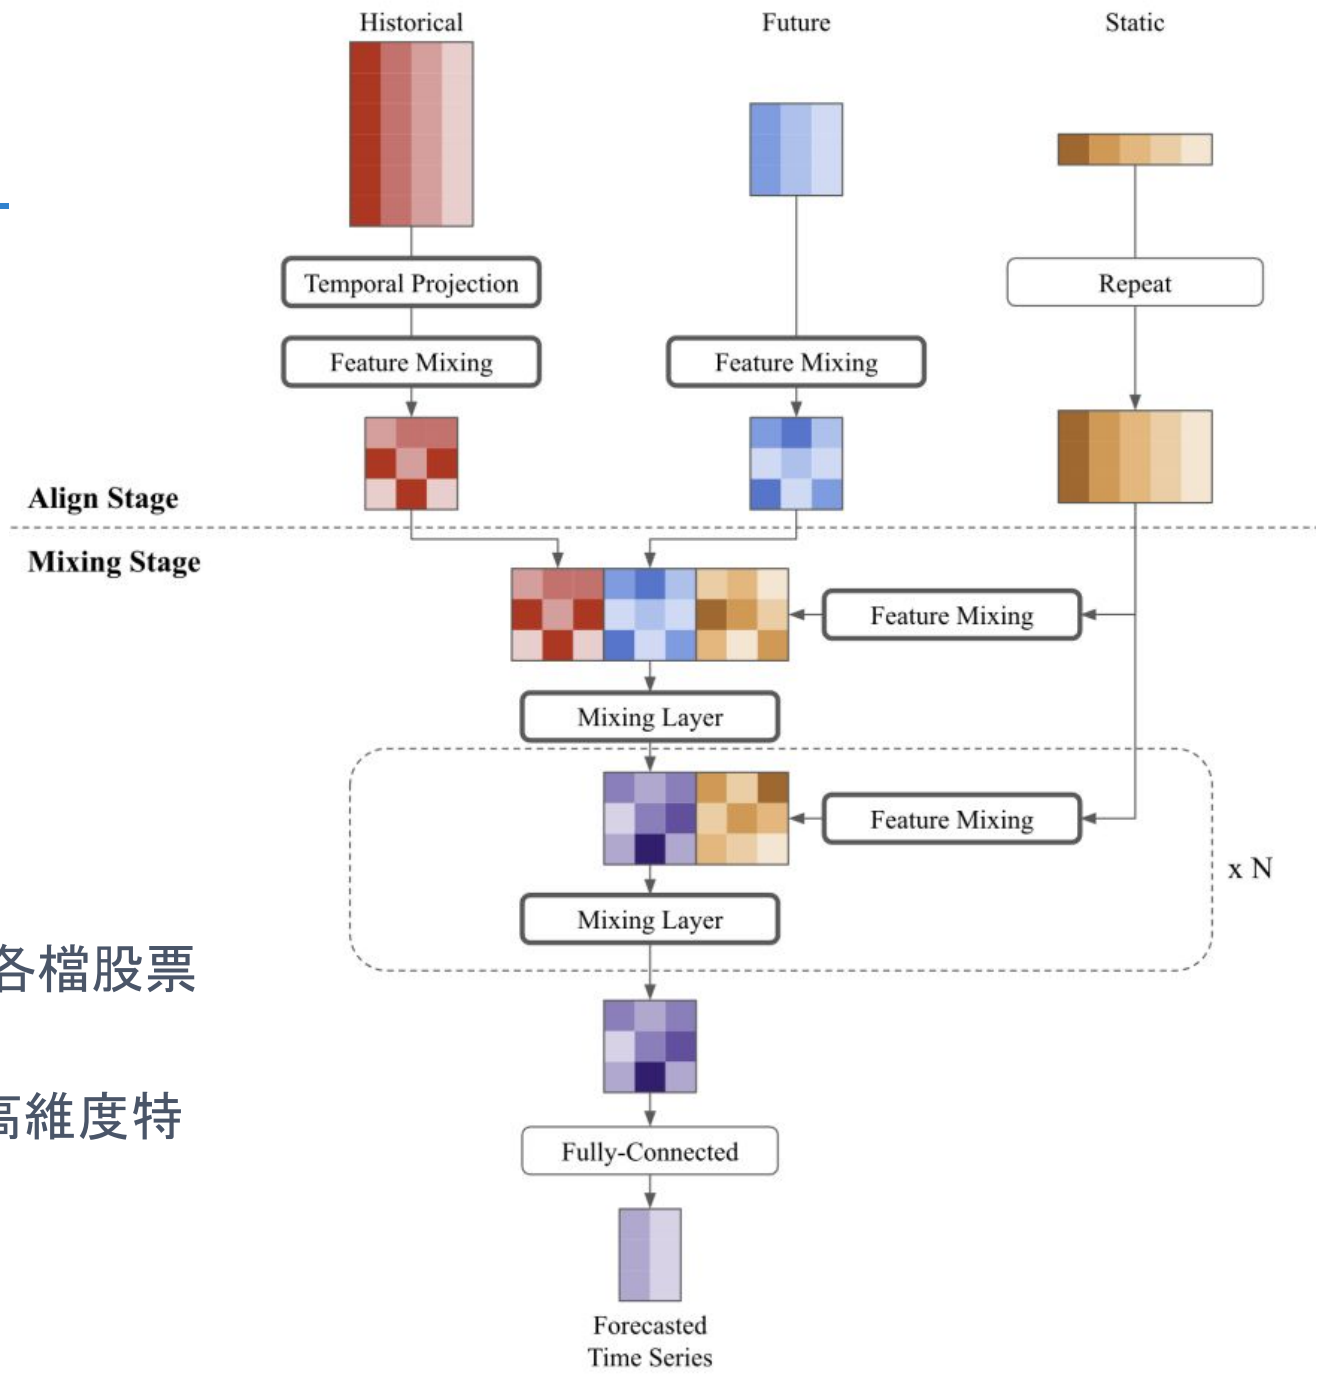

GARCH-Informed Loss Function

根據Xu et al.(2024)複合loss function，結合深度學習與 GARCH模型

$$\mathrm{MSE}_{\mathrm{total}} = \lambda \cdot \mathrm{MSE}\left(\sigma^2_{\mathrm{true}}, \hat{\sigma}^2_{\theta}\right) + (1-\lambda) \cdot \mathrm{MSE}\left(\hat{\sigma}^2_{\mathrm{GARCH}}, \hat{\sigma}^2_{\theta}\right)$$

Parameter 參數意義

控制資料驅動擬合與經濟理論之間的平衡

MSE_{true}: 模型預測值與真實波動率的誤差 (純數據驅動)

MSE_{GARCH}: 模型預測值與 GARCH 預測值的誤差

lambda: 比例控制

- $\lambda \to 1$ 純深度學習(高偏差風險)。
- $\lambda \to 0$ 完全模擬GARCH(高穩定性)。

Inductive Bias

透過引入 GARCH 項，我們可以對偏離既定計量經濟學理論過大的模型進行懲罰。

Experimental Setup & Optimization

Hyperparameter Tuning

Framework: Optuna 與樹狀 Parzen 估計器 (TPE) 結合。針對所有不同的模型，我們都會先進行超參數搜尋後再進行後續訓練，確保輸出最佳化。

Data Split: Train (70%), Val (20%), Test (10%).

Note: 我們使用 90 天滾動視窗重新估計 GARCH 模型，以確保與固定視窗 DL 模型進行公平比較。

Table 2: Hyperparameter search space

Hyperparameter	TSMixer	LSTM
Hidden size	[16, 32, 64]	[16, 32, 64]
Dropout rate	[0.1, 0.2, 0.3]	[0.1, 0.2, 0.3]
Feed-forward hidden size	[16, 32, 64]	–
Number of blocks	[1, 2, 4]	–
Number of layers	–	[1, 2, 3]
Learning rate	$[10^{-2}, 10^{-4}]$	$[10^{-2}, 10^{-4}]$
Gamma	0.99	0.99
Learning rate schedule	Exponential	Exponential
Batch size	32	32
Gradient clipping	0.5	0.5
Epochs	10	10
Early stopping patience	2	2
Input length	90	90

Results: Baseline Model Comparison

使用標準loss function（λ=1）對模型進行比較。TSMixer 的MAE表現優於GARCH和LSTM，但在RMSE、QLIKE表現較差。

Table 3: Out-of-sample performance of baseline models (standard loss, $\lambda = 1$).

Model	MAE	RMSE	QLIKE
GARCH	5.1794	11.3005	2.2827
GJR-GARCH	5.2712	11.6947	2.2905
TGARCH	5.2545	11.4623	2.2775
LSTM	4.4424	11.7723	2.7493
LSTM-Covariates	26.4135	82.8169	3.9617
TSMixer	4.3267	11.7544	2.6421
TSMixer-Covariates	4.3056	11.7658	2.7974

Key Findings

1. **TSMixer（MAE 4.3267）的表現優於 GARCH（5.1794）。**
2. **LSTM 過度擬合：**「LSTM + 協變數」模型誤差龐大（MAE 26.4），證明傳統 RNN 在處理高維度雜訊時表現不佳。
3. **TSMixer 能夠處理協變量且不會出現過度擬合，但提升效果有限。**

The lambda Trade-off: Accuracy vs. Stability

lambda可做為在平均 絕對誤差和尾部風險指標之間的平衡參數。

低λ值（接近GARCH模型）：RMSE/QLIKE值較低（尾部風險較低）。

高λ值（純ML模型）：MAE值較低（平均適合度較高）。

當λ = 0.3時，三項指標整體而言較佳

Table 4: Out-of-sample performance under the mixed loss function for different values of λ.

	λ	0	0.05	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	0.95	1
GARCH	MAE							5.18						
	RMSE							11.30						
	QLIKE							2.28						
GJR-GARCH	MAE							5.27						
	RMSE							11.69						
	QLIKE							2.29						
TGARCH	MAE							5.25						
	RMSE							11.46						
	QLIKE							2.28						
LSTM	MAE	4.69	4.99	4.96	4.80	4.67	4.63	4.57	4.53	4.48	4.45	4.45	4.43	4.44
	RMSE	11.27	11.17	11.18	11.20	11.27	11.62	11.41	11.53	11.52	11.63	11.73	11.72	11.77
	QLIKE	2.26	2.26	2.22	2.28	2.30	2.33	2.34	2.41	2.46	2.53	2.68	2.73	2.75
LSTM-Covariates	MAE	5.08	4.99	4.91	4.74	4.78	5.31	6.90	10.75	22.06	15.04	13.64	15.47	26.41
	RMSE	11.25	11.18	11.16	11.30	11.54	12.45	15.91	23.76	49.44	36.85	35.57	40.66	82.82
	QLIKE	2.27	2.26	2.26	2.28	2.33	2.44	2.57	2.75	3.06	3.37	3.53	3.63	3.96
TSMixer	MAE	4.95	4.89	4.83	4.74	4.65	4.58	4.52	4.46	4.42	4.38	4.35	4.34	4.33
	RMSE	11.16	11.16	11.17	11.21	11.29	11.35	11.42	11.49	11.56	11.63	11.69	11.73	11.75
	QLIKE	2.20	2.20	2.21	2.22	2.24	2.27	2.30	2.35	2.40	2.46	2.54	2.59	2.64
TSMixer-Covariates	MAE	4.95	4.86	4.83	4.68	4.58	4.50	4.44	4.38	4.35	4.32	4.30	4.30	4.31
	RMSE	11.24	11.27	11.27	11.30	11.34	11.39	11.40	11.50	11.54	11.62	11.67	11.74	11.77
	QLIKE	2.24	2.24	2.24	2.27	2.28	2.31	2.33	2.42	2.48	2.56	2.65	2.71	2.80

Case Study: TSMC (2330) Forecasts

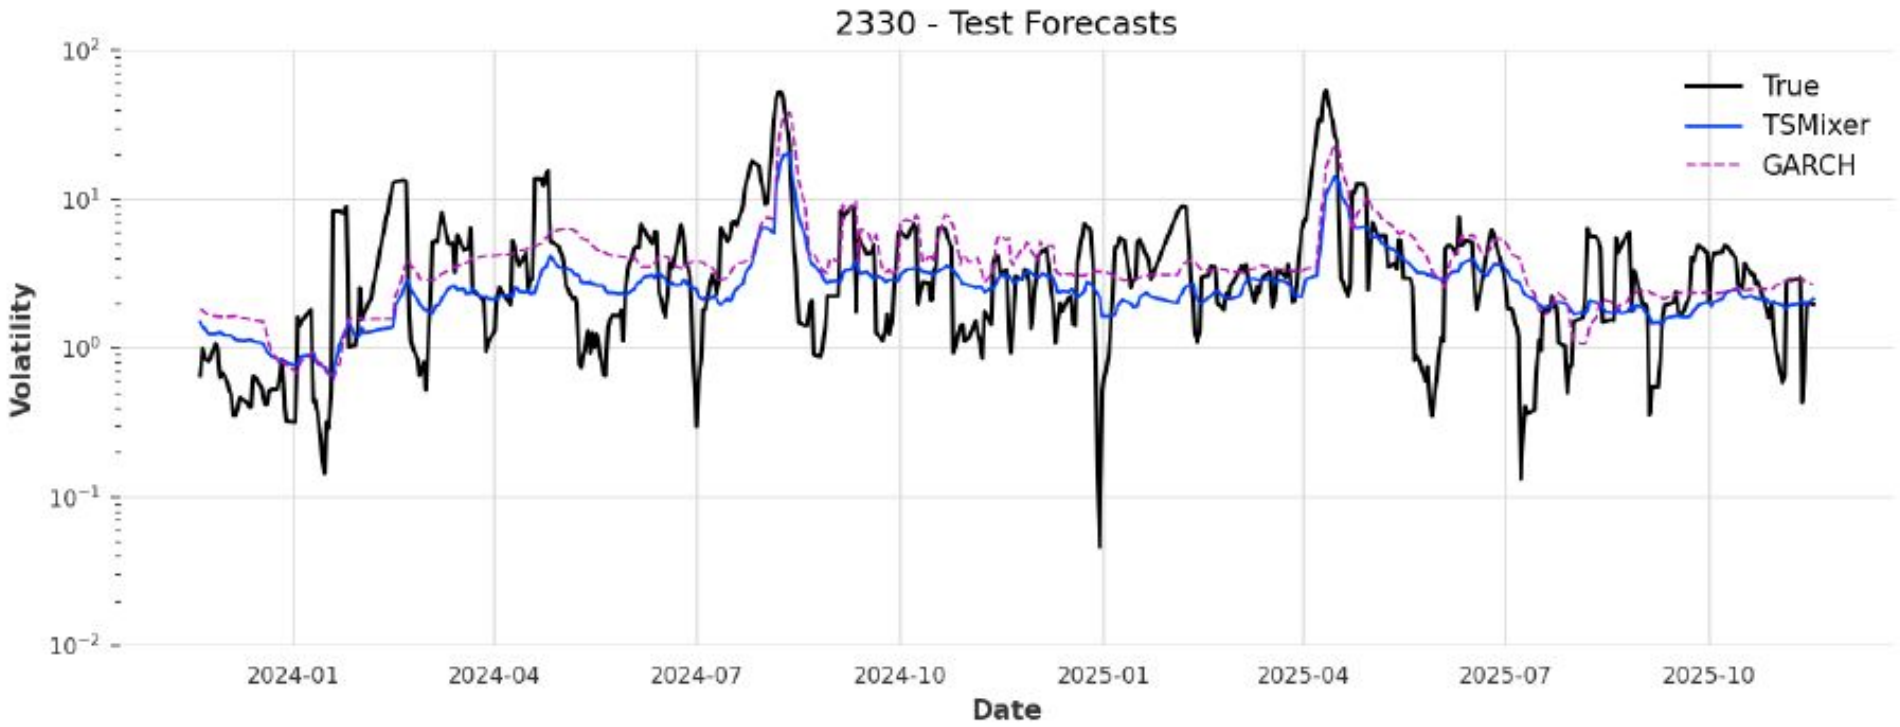

- 上圖展示了真實波動率（黑色）、GARCH 預測（紫色）與 TSMixer 預測（藍色, lambda=0.3）的路徑比較。**與獨立 GARCH 相比，TSMixer可降低約10%的MAE。**
- GARCH 模型在面對市場衝擊時容易**過度反應 (Overshoot)**，且回復速度較慢；相比之下，TSMixer 的預測路徑更加**平滑且穩定**，既能捕捉波動上升的趨勢，又有效過濾了不必要的噪聲，這解釋了為何其 MAE 表現優於 GARCH。

Robustness & Ablation Studies: Market Index Validation

Table 5: Out-of-sample performance on the market index under the mixed loss function.

Model	Metric	λ=0	0.05	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	0.95	1
GARCH	MAE							2.38						
	RMSE							7.64						
	QLIKE							1.57						
GJR-GARCH	MAE							2.45						
	RMSE							7.60						
	QLIKE							1.59						
TGARCH	MAE							2.31						
	RMSE							7.17						
	QLIKE							1.58						
LSTM	MAE	2.27	2.24	2.19	2.18	2.17	2.29	2.25	2.16	2.12	2.19	2.09	2.17	2.19
	RMSE	7.77	7.79	7.79	7.84	7.89	8.08	8.03	8.03	8.10	8.20	7.71	7.78	7.73
	QLIKE	1.55	1.56	1.58	1.61	1.61	1.65	1.61	1.85	1.98	2.24	1.99	2.38	2.66
TSMixer	MAE	2.26	2.23	2.19	2.15	2.11	2.09	2.10	2.10	2.08	2.07	2.05	2.04	2.03
	RMSE	7.57	7.56	7.52	7.61	7.74	7.86	7.92	8.00	8.06	8.10	8.12	8.13	8.14
	QLIKE	1.49	1.50	1.51	1.52	1.54	1.56	1.56	1.62	1.71	1.80	1.90	1.95	2.01

- 即便在單一資 產（無法參數共享）下，TSMixer 依然擊敗 GARCH，並且比Xu et al.(2024)的LSTM方法更為優異

Robustness & Ablation Studies: Log vs. Original Scale

Table 6: Comparison between log-scale and original-scale volatility targets for TSMixer.

Model	Metric	λ=0	0.05	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	0.95	1
GARCH	MAE							5.18						
	RMSE							11.30						
	QLIKE							2.28						
GJR-GARCH	MAE							5.27						
	RMSE							11.69						
	QLIKE							2.29						
TGARCH	MAE							5.25						
	RMSE							11.46						
	QLIKE							2.28						
TSMixer (log)	MAE	4.95	4.89	4.83	4.74	4.65	4.58	4.52	4.46	4.42	4.38	4.35	4.34	4.33
	RMSE	11.16	11.16	11.17	11.21	11.29	11.35	11.42	11.49	11.56	11.63	11.69	11.73	11.75
	QLIKE	2.20	2.20	2.21	2.22	2.24	2.27	2.30	2.35	2.40	2.46	2.54	2.59	2.64
TSMixer (no-log)	MAE	5.17	5.17	5.20	5.19	5.15	5.13	5.10	5.08	5.07	5.04	5.03	5.03	5.02
	RMSE	11.13	11.13	11.14	11.15	11.15	11.16	11.17	11.19	11.19	11.21	11.22	11.23	11.24
	QLIKE	2.35	2.27	2.30	2.25	2.27	2.24	2.31	2.25	2.27	2.55	2.32	2.31	2.54

- 以Log-scale預測整體Bias較低，但在極端波動下表現較不理想。混合 Loss 可在兩者間取得平衡。

Discussion: Lessons Learned

Why DeepAR Failed?

我們最初嘗試使用 DeepAR(機率循環神經網路)但是遇到以下問題。

1. **Error Accumulation**:遞歸式單步預測(Recursive one-step-ahead prediction)在長期預測中會出現漂移。
2. 單變量特性:無法有效模擬多個 Alpha 因子與波動率之間的即時交互作用。

The Role of Alpha 101

與預期相反,「更多數據」並非總是更好。可能是因為以下原因導致:

1. 訊號衰減:已公佈的alpha值對波動率的預測能力較弱。
2. 雜訊比:如果沒有GARCH資訊, LSTM難以在因子雜訊中找到訊號。

Conclusion

Architecture Win

TSMixer + 共享參數為多資產波動率建立了新的SOTA，在各指標皆優於LSTM 和 GARCH。

Method Innovation

GARCH-loss成功結合計量經濟和深度學習，為風險管理提供了一個可調整的方法。

Practical Impact

根據此架構，交易人員可以依此混合模型來執行交易策略，通過更改骨架模型跟lambda值來獲得最適結果

我們的模型結合了 GARCH 的穩健特性 與 TSMixer 的高彈性結構，透過混合式損失函數與參數共享設計，在波動率預測上同時兼顧準確度與風險控管表現。

Team Roles & Contribution

Domain	Member	Key Contributions
Theory & Econometrics	蔡宇傑 (Leader)	Architecture design, GARCH theory, Time-series CV design (70/20/10), Parallelization, Paper writing.
	黃和謙	DeepAR analysis (Deprecated models), Financial literature review, Data organization.
ML System & Ops	柯宥圻 (PM)	Project Management, TSMixer implementation, Pipeline development, Visualization, Presentation.
Data Engineering	高大剛	Alpha 101/Volume factors, TSMixer variants, Deep comparison of GARCH vs DL.
EDA & Visualization	姚暐	Data Viz, Correlation Heatmaps, Rank Normalization analysis, Reporting.
	郭宥真	Data Viz, Distribution analysis, Reporting.

Q & A

Thank you for your attention.

GARCH-Informed Applied Deep Learning Project | NTU